Projet 6 - Optimisez la gestion des données d'une boutique avec R ou Python

MK
Data Analyst
05 octobre 2025

Analyses Exploratoires des Données

3 fichiers :

- ERP : extraction du logiciel de gestion de l'entreprise
- WEB : extraction du site web
- LIAISON : table liant les références produit entre ces deux BDD

Normalisation de la BDD :

- Fusion des tables
- Suppression/Correction
  - des NaN, des doublons, valeurs aberrantes, des colonnes non pertinentes

Analyses Exploratoires des Données

Table erp :

- Stocks erronés

	product_id	onsale_web	price	stock_quantity	stock_status	purchase_price	stock_status_2
4	4039	1	46.0	3	outofstock	23.77	instock
398	4885	1	18.7	0	instock	9.66	outofstock
449	4973	0	10.0	-10	outofstock	4.96	instock
573	5700	1	44.5	-1	outofstock	22.30	instock

- Prix négatifs

	product_id	onsale_web	price	stock_quantity	stock_status	purchase_price	stock_status_2
151	4233	0	-20.0	0	outofstock	10.33	outofstock
469	5017	0	-8.0	0	outofstock	4.34	outofstock
739	6594	0	-9.1	19	instock	4.61	instock

Analyses Exploratoires des Données

Table erp :

- Prix de vente incohérents

```
df_erp.loc[df_erp["price"]<df_erp["purchase_price"]]
```

	product_id	onsale_web	price	stock_quantity	stock_status	purchase_price
210	4355	1	12.65	97	instock	77.48
391	4864	0	8.30	0	outofstock	9.99
724	6324	0	92.00	18	instock	99.00
817	7196	0	31.00	55	instock	31.20

Analyses Exploratoires des Données

Table web :

- Codification
- Produits et pièces jointes

	sku	total_sales	tax_status	product_type	post_title
272	13127-1	4.0	taxable	Vin	Clos du Mont-Olivet Châteauneuf-du-Pape 2007
842	bon-cadeau-25-euros	7.0	NaN	Autre	Bon cadeau de 25€
1117	13127-1	4.0	NaN	Vin	Clos du Mont-Olivet Châteauneuf-du-Pape 2007
1387	bon-cadeau-25-euros	7.0	taxable	NaN	Bon cadeau de 25€

- 714 produits ont des doublons (715-nan)

```
len(df_web['sku'].unique())
```

```
715
```

Analyses Exploratoires des Données

Table web :

- 83 lignes sont vides

```
df_web.loc[df_web['sku'].isnull()].info()
```

```
<class 'pandas.core.frame.DataFrame'>
Index: 85 entries, 8 to 1457
Data columns (total 13 columns):
 #   Column          Non-Null Count  Dtype
---  ------          --------------  -----
 0   sku             0 non-null      object
 1   total_sales     2 non-null      float64
```

- 2 articles sans sku

mais des ventes négatives

1084	NaN	-56.0	taxable	Vin	Pierre Jean Villa Condrieu Jardin Suspendu 2018
1086	NaN	NaN	NaN	NaN	NaN
1087	NaN	-17.0	taxable	Vin	Pierre Jean Villa Côte Rôtie Fongeant 2017

Analyses Exploratoires des Données

Table liaison :

- 91 id_web sans correspondance avec un product_id

```
df_liaison.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 825 entries, 0 to 824
Data columns (total 2 columns):
 #   Column      Non-Null Count  Dtype
---  ------      --------------  -----
 0   id_web      734 non-null    object
 1   product_id  825 non-null    int64
dtypes: int64(1), object(1)
memory usage: 13.0+ KB
```

```
<class 'pandas.core.frame.DataFrame'>
Index: 734 entries, 0 to 824
Data columns (total 2 columns):
 #   Column      Non-Null Count  Dtype
---  ------      --------------  -----
 0   id_web      734 non-null    object
 1   product_id  734 non-null    int64
dtypes: int64(1), object(1)
memory usage: 17.2+ KB
```

Fusion ou consolidations des données

ERP	LIAISON	WEB
product_id	id_web	sku
	product_id	

FINAL
product_id

- Suppression des colonnes non pertinentes
- Vigilance
  - au type de fusion
  - aux doublons, NaN
  - aux lignes sans correspondance

Analyses univariées du prix

Indicateurs : prix moyen = 32.31 ecart-type = 27.62

Outliers : Z-index(3) : prix>115.17 écart interquartile : prix>83.7

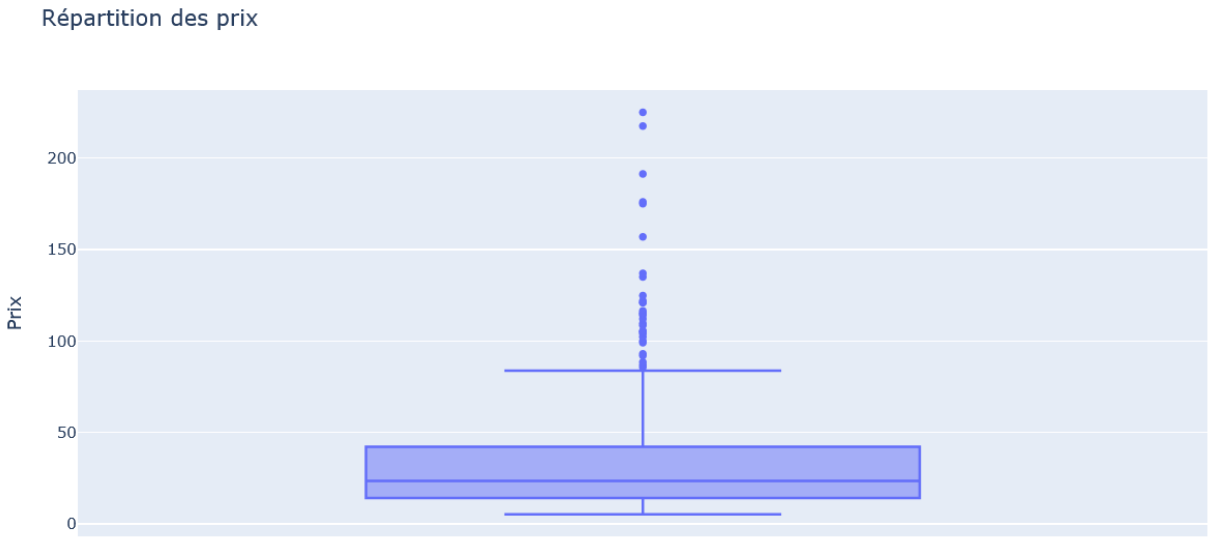

Analyses univariées du prix

Attention : outliers ≠ anomalie

product_id	onsale_web	price	stock_quantity	stock_status	purchase_price	id_web	sku	total_sales	product_type	post_title	post_type	_merge	z_scores
4352	1	225.0	0	outofstock	137.81	15940	15940	11.0	Champagne	Champagne Egly-Ouriet Grand Cru Millésimé 2008	product	both	6.976466
5001	1	217.5	18	instock	116.87	14581	14581	2.0	Vin	David Duband Charmes-Chambertin Grand Cru 2014	product	both	6.704924
5892	1	191.3	98	instock	116.06	14983	14983	6.0	Champagne	Coteaux Champenois Egly-Ouriet Ambonnay Rouge ...	product	both	5.756336
4402	1	176.0	11	instock	78.25	3510	3510	3.0	Cognac	Cognac Frapin VIP XO	product	both	5.202390
5767	1	175.0	12	instock	90.42	15185	15185	4.0	Vin	Camille Giroud Clos de Vougeot 2016	product	both	5.166184
4406	1	157.0	12	instock	69.08	7819	7819	4.0	Cognac	Cognac Frapin Château de Fontpinot 1989 20 Ans...	product	both	4.514482
4904	1	137.0	9	instock	67.95	14220	14220	3.0	Vin	Domaine Des Croix Corton Charlemagne Grand Cru...	product	both	3.790369
6126	1	135.0	138	instock	80.33	14923	14923	5.0	Champagne	Champagne Gosset Célébris Vintage 2007	product	both	3.717958
5612	1	124.8	19	instock	66.41	14915	14915	1.0	Vin	Domaine Weinbach Gewurztraminer Grand Cru Furs...	product	both	3.348660

Analyses complémentaires
CA, quantités, stocks, taux de marge et corrélations

CA

CA Total Site Web : 143286

80% du CA : 432 articles
Proportion : 60.67 %

Observations :

- Vins et champagnes

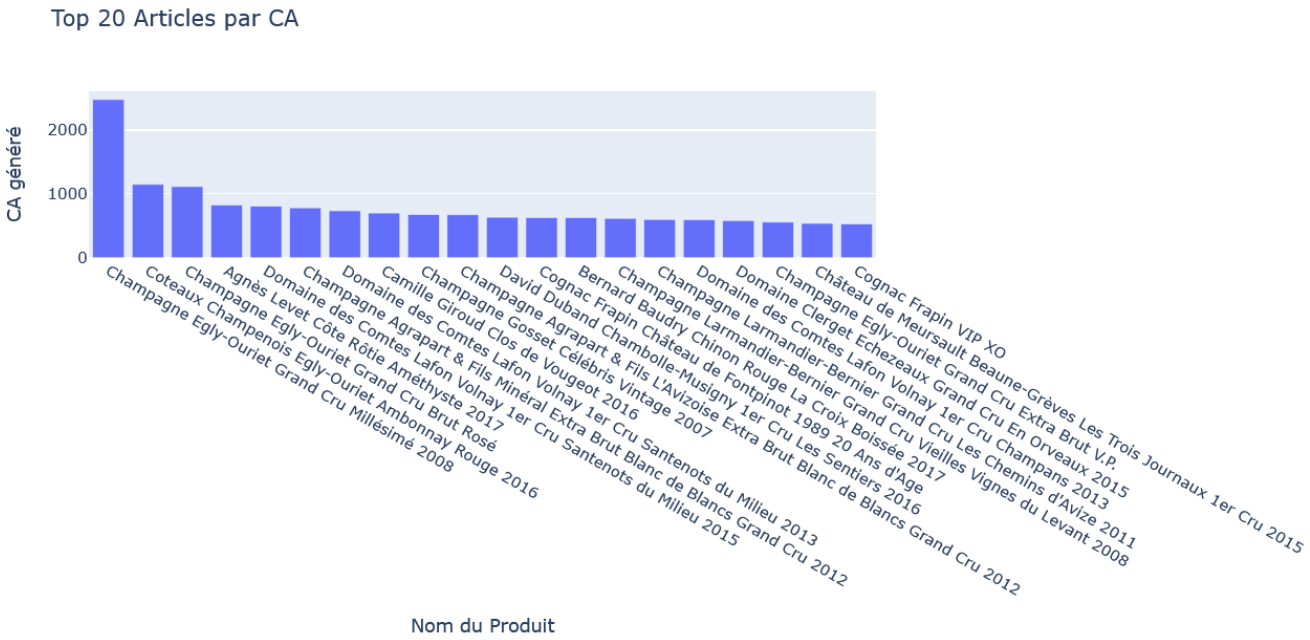

Analyses complémentaires
CA, quantités, stocks, taux de marge et corrélations

Volume des ventes

```
Volume des ventes: 5740.0
80% du volume de ventes : 431 articles
Proportion : 60.53 %
```

Observations :

- Majorité de Vins

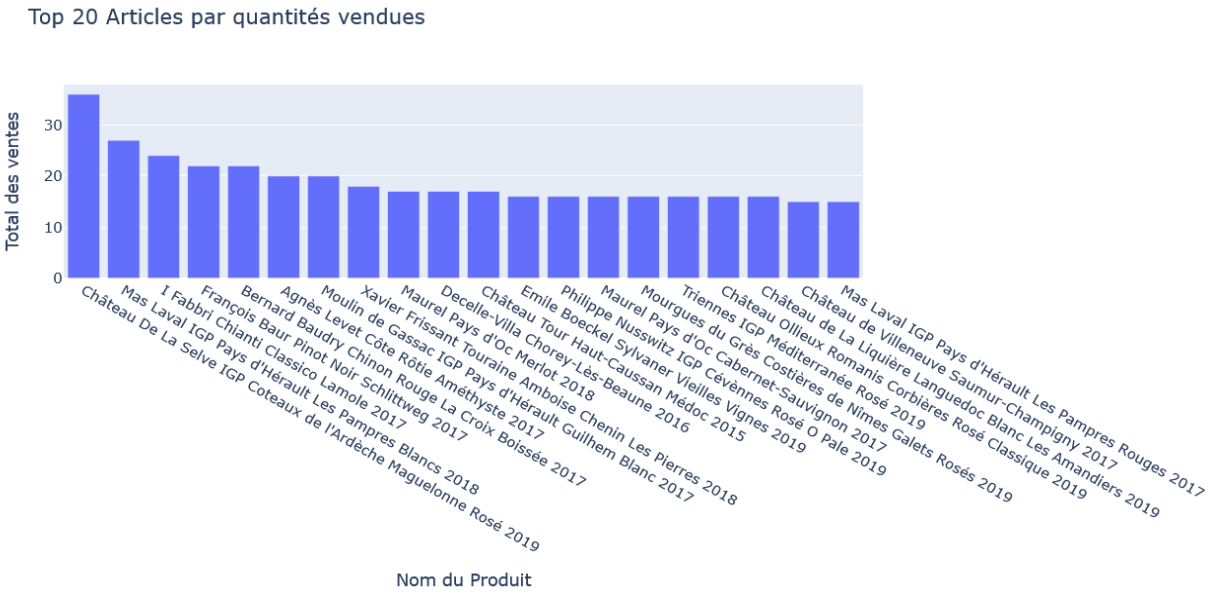

Analyses complémentaires
CA, quantités, stocks, taux de marge et corrélations

Stocks

Nombre de produits en stock : 16711

Valorisation totale des stocks : 276859 €

Observations :

- Très grande majorité de champagnes

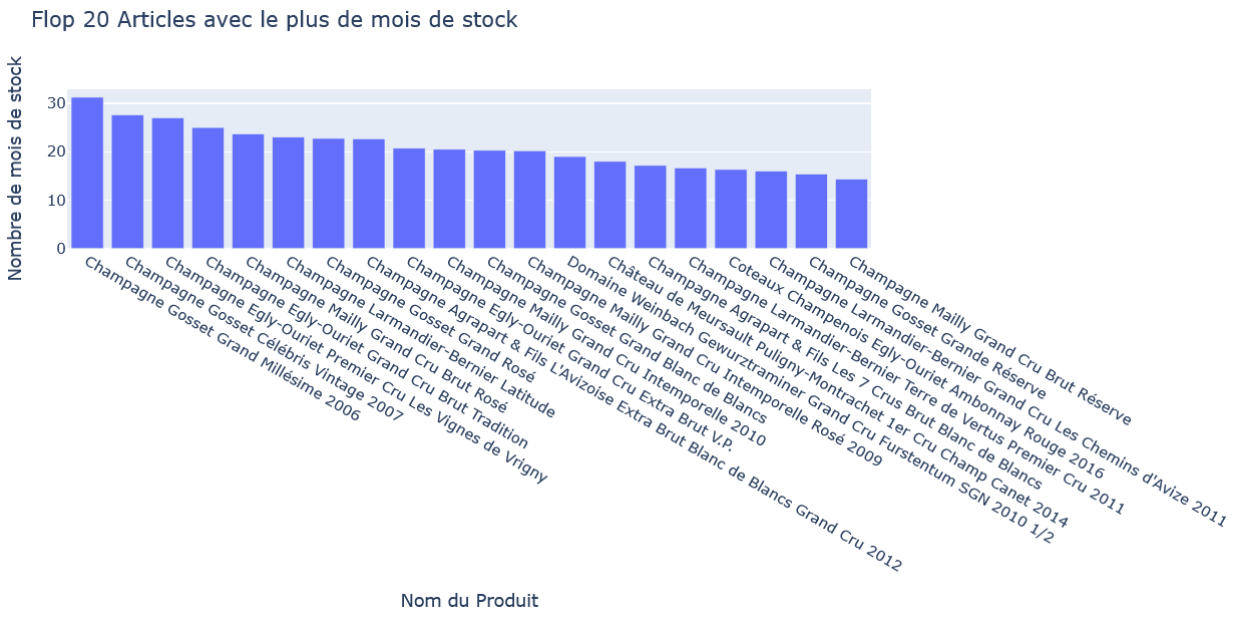

Analyses complémentaires
CA, quantités, stocks, taux de marge et corrélations

Taux de marge

```
Taux de marge minimum : 0.29
Taux de marge maximum : 0.91
```

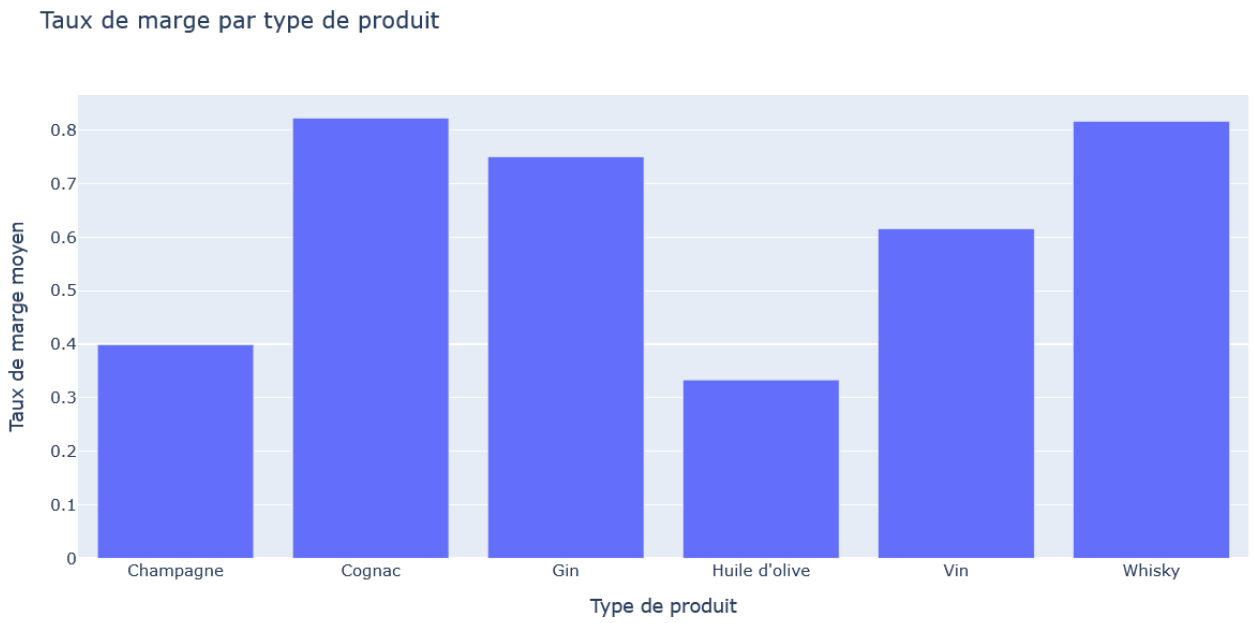

Taux de marge

Observations :

- Mise en évidence d'une anomalie (erreur de saisie)

```
Taux de marge minimum : -0.86
Taux de marge maximum : 0.91
```

```
df_final.loc[df_final['taux_marge']<0]
```

	product_id	onsale_web	price	stock_quantity	stock_status	purchase_price	id_web	sku
79	4355	1	12.65	97	instock	77.48	12589	12589

Analyses complémentaires
CA, quantités, stocks, taux de marge et corrélations

Corrélations

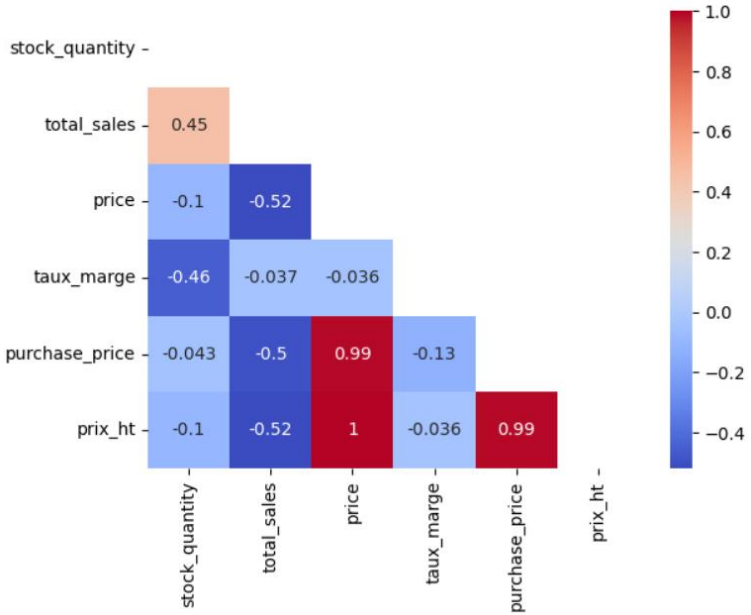

Observations :

- Relations linéaires entre le prix d'achat, le prix HT et le prix de vente
- Plus le prix baisse, plus les ventes augmentent
- Stocks à revoir pour certains produits

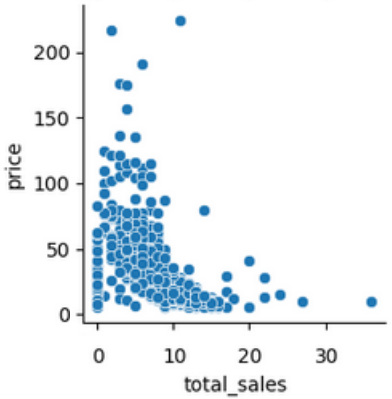

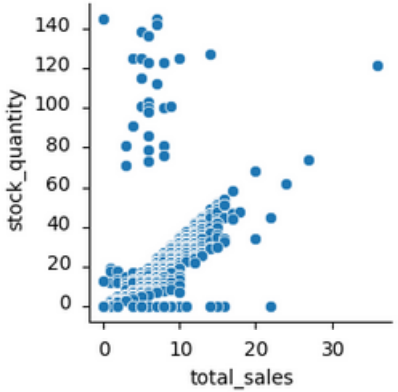

Actions pour la suite

Archiver les anciennes BDD
Sécuriser les sauvegardes
Alimenter la BDD unifiée
Trouver les informations correctes concernant les items supprimés

Point sur les compétences apprises

- *Qu’est-ce qui s’est bien passé pour vous dans ce travail de nettoyage ?*

Je commence à acquérir des automatismes au niveau de l’exploration et du nettoyage des données

- *Qu’est-ce que vous avez trouvé le plus difficile ?*

La fusion via la table liaison, qui n’était pas difficile techniquement mais m’a fait douter sur les clés à utiliser

- *Sur quelles tâches est-ce que vous pensez avoir besoin de plus d'entraînement ?*

Sur le plotting avec plotly_express, qui a l’air d’être un outil puisssant